뉴스 빅데이터와 토픽 모델링 기반의 한국형 경제 이슈 국면 탐지 및 시장·심리 지표 반응 분석

Topic Modeling-Based Detection of Korean Economic Issue Regimes and Market Sentiment Reaction Analysis Using News Big Data

[저자 미정 (심사본)]

한국성서대학교 AI융합학부 (School of AI Convergence, Korean Bible University, Seoul, 01757 Korea)

요 약

본 연구는 2021년 1월부터 2026년 7월까지(총 67개월) 국내 3대 주요 경제 일간지(매일경제, 서울경제, 한국경제)에서 수집한 931,709건의 경제 뉴스 기사와 한국은행 경제통계시스템(ECOS)의 5대 핵심 거시금융 지표를 대상으로 텍스트 마이닝 및 계량시계열 분석을 통해 한국형 경제 이슈 국면 탐지 체계를 구축하고 시장·심리 지표의 반응 패턴을 실증 분석하였다. 형태소 분석 기반의 키워드 마이닝과 TF-IDF 가중치를 적용하여 931,709 × 28,343 차원의 고차원 문서-어휘 희소행렬을 구축하였으며, 비음수 행렬 분해(NMF)를 통해 14개의 잠재 토픽을 도출하고 경제학적 정합성에 따라 8대 핵심 경제 국면(금리·물가, 부동산, 가계대출, 대외통상, AI반도체, 시황, 기업실적, 자본거래)으로 체계화하였다. 특히 기존 연구의 단일 지배 국면(Single Dominant) 강제로 인한 정보 절단 편향(Truncation Bias)을 극복하기 위해, 표준화 z점수 기반의 다중 국면 활성화 체계(z >= 0.5)를 제안·적용하였다. 분석 결과, 한국 경제는 전체 기간의 76.1%에서 2~3개의 복합 국면이 동시에 공존하는 구조적 다중성을 보였다. 8대 국면 비중 벡터를 활용하여 Newey-West HAC 견고 회귀분석을 수행한 결과, 코스피 주가 변동성에 대해 22.8%의 설명력(F = 4.75, p = 0.00016)과 코스피 월간 수익률에 대해 18.1%의 설명력(F = 2.68, p = 0.0106)을 유의하게 입증하였다. 또한 시차 교차상관(Lead-Lag) 분석 결과, '금리·물가' 국면은 소비자심리지수(CCSI)를 1개월 선행(r = -0.665), 한국은행 기준금리 조정을 2개월 선행(r = +0.341)하였으며, 2022~2023년 본격 금리 인상기 7회에 대해 100%의 사전 경고 적중률을 기록하였다. 본 연구는 발표 시차가 존재하는 전통적 거시 통계를 보완하여 비정형 빅데이터로부터 경제 위험을 실시간으로 감지하고 조기 경보할 수 있는 실증적 분석 프레임워크를 제공한다.

키워드 : 경제 뉴스 빅데이터, 텍스트 마이닝, 토픽 모델링, 비음수 행렬 분해(NMF), 다중 국면 활성화, HAC OLS 회귀, 조기경보시스템

ABSTRACT

This study constructs a data-driven economic issue regime detection framework and empirically investigates the reaction patterns of financial markets and consumer sentiment using 931,709 economic news articles collected from three major Korean business dailies (Maeil Business Newspaper, Seoul Economic Daily, and Korea Economic Daily) and five macroeconomic/financial indicators from the Bank of Korea's ECOS database between January 2021 and July 2026 (67 months). We constructed a high-dimensional TF-IDF document-term sparse matrix (931,709 x 28,343), extracted 14 latent topics via Non-negative Matrix Factorization (NMF), and structured them into eight economically consistent regimes: Interest Rate & Inflation, Real Estate, Household Debt, Foreign Trade, AI & Semiconductor, Stock Market, Corporate Earnings, and Capital Transactions. To overcome the severe truncation bias inherent in traditional single-dominant regime approaches, we proposed a multi-regime activation framework based on standardized z-scores (z >= 0.5). Empirical results show that 76.1% of the total sample period exhibited a coexistence of two to three multiple economic regimes. Newey-West HAC robust OLS regressions revealed that the eight regime attention shares explained 22.8% of KOSPI return volatility (F = 4.75, p = 0.00016) and 18.1% of monthly KOSPI returns (F = 2.68, p = 0.0106). Furthermore, lead-lag cross-correlation analysis confirmed that the 'Interest Rate & Inflation' regime leads the Consumer Sentiment Index (CCSI) by one month (r = -0.665) and the Bank of Korea base rate adjustments by two months (r = +0.341), achieving 100% early-warning precision during the 2022-2023 rate hike cycle. This study establishes a robust data-driven early warning framework for monitoring macroeconomic risks and market volatility.

Keywords : Economic News Big Data, Text Mining, Topic Modeling, Non-negative Matrix Factorization (NMF), Multi-Regime Activation, HAC OLS Regression, Early Warning System

Ⅰ. 서 론

현대 거시경제 시스템은 글로벌 지정학적 갈등, 인플레이션의 급격한 확산, 주요국 중앙은행의 가파른 긴축 통화정책, 글로벌 공급망 블록화, 그리고 생성형 인공지능(AI)과 첨단 반도체 패권 경쟁 등 복합적인 동인들이 동시다발적으로 상호작용하며 급속한 변동성을 겪고 있다[1-3]. 이러한 거시 환경의 복잡성과 불확실성 증대는 주식시장, 외환시장 등 전통적 금융자산의 가격 급변동을 유발할 뿐만 아니라, 가계 및 기업 등 경제 주체들의 심리적 기대를 급격히 냉각시키는 연쇄 파급효과를 초래한다[4-6]. 이에 따라 통화정책을 집행하는 중앙은행과 금융감독당국, 투자은행 및 실물 경제 주체들은 거시경제 충격을 조기에 탐지하고 시장의 동태적 반응을 예측할 수 있는 실시간 모니터링 체계의 구축을 강력히 요구하고 있다.

그러나 통계청의 산업활동동향, 경기종합지수, 한국은행의 국민계정(GDP) 등 전통적인 거시경제 지표는 원시 통계 자료의 취합, 정제, 전수 조사 및 보정 작업으로 인해 발표 시점까지 최소 1개월에서 1개 분기 이상의 구조적인 발표 시차(Publication Lag)를 불가피하게 수반한다[1, 5]. 이로 인해 거시 충격이 실물 경제와 금융시장에 본격적으로 파급된 이후에야 사후적으로 통계가 확인되는 '정책 시차(Policy Lag)' 문제가 발생한다. 이러한 공식 통계의 시차적 한계를 극복하기 위해 매일 대규모로 생산되는 뉴스 미디어의

비정형 텍스트 빅데이터를 자연어 처리(NLP) 기법으로 분석하여 경제 상황을 신속히 파악하려는 연구가 세계적으로 주목받아 왔다[1-5].

하지만 기존의 텍스트 기반 경제 분석 연구는 크게 두 가지 방법론적 한계를 내포하고 있다. 첫째, 상당수의 선행 연구는 뉴스 기사의 긍정·부정 감성을 판별하여 경제 전반의 분위기를 하나의 연속적인 '1차원 단일 점수(Sentiment Score)'로 압축하는 데 치중하였다[4-6]. 그러나 동일한 비관적 감성이 관측되더라도, 그 원인이 기준금리 인상인지, 부동산 시장 붕괴인지, 대외 무역수지 악화인지에 따라 시장 참가자들이 체감하는 위험과 실제 자산 가격의 조정 경로는 근본적으로 상이하다. 둘째, 텍스트 기반으로 거시 국면을 분류한 연구들의 경우, 특정 월에 비중이 가장 높은 단 1개의 토픽만을 대표 상태로 강제하는 '단일 지배 국면(Single Dominant Regime)' 접근법을 관행적으로 적용하였다. 하지만 2022년과 같이 고물가, 급격한 기준금리 인상, 원/달러 환율 급등이 중첩되었던 복합 위기 국면에서 1등 이슈 하나만 채택하고 나머지 주요 이슈를 버리는 방식은 전체 경제 정보의 70% 이상을 누락시키는 심각한 정보 절단 편향(Truncation Bias)을 필연적으로 야기한다.

이에 본 연구는 2021년 1월부터 2026년 7월까지 국내 3대 대표 경제 일간지(매일경제, 서울경제, 한국경제)에서 발행된 931,709건의 전수 뉴스 코퍼스와 한국은행 ECOS 5대 핵심 지표를 통합적으로 연계하여, 복합 경제 이슈를 손실 없이 추적하는 새로운 국면 탐지 방법론을 제안한다. 비음수 행렬 분해(NMF)를 통해 14개 잠재 토픽을 도출하고 경제학적 정합성에 따라 8대 핵심 국면으로 체계화한 뒤, 표준화 z점수 기반의 다중 국면 활성화 체계(z >= 0.5)를 구축한다. 나아가 Newey-West HAC 견고 회귀분석과 시차 교차상관(Lead-Lag) 분석, 그리고 전환 시점 전후의 이벤트 스터디를 통해 뉴스가 실제 주식시장 변동성과 정책금리 및 소비심리를 선행 예측하는지를 엄밀히 검증한다.

본 연구의 주요 내용과 구성은 다음과 같다:

첫째, 93만 건의 경제 뉴스 코퍼스로부터 고차원 TF-IDF 희소행렬을 구축하고 NMF 토픽 모델링을 통해 한국 경제를 대변하는 8대 핵심 경제 이슈 국면 체계를 확립한다.

둘째, 단일 지배 국면의 한계를 극복하는 다중 국면 활성화 체계(z >= 0.5)를 설계하여 복합 위기 상황에서의 이슈 공존 구조를 실증적으로 규명한다.

셋째, Newey-West HAC 견고 회귀분석을 적용하여 8대 국면 비중이 코스피 주가 변동성 및 월간 수익률에 미치는 통계적 설명력을 검정한다.

넷째, 시차 교차상관 행렬 및 67개월 전수 사건 분석을 통해 뉴스의 경제지표 선행성(Lead-Lag Effects)과 기준금리 인상 조기경보 정밀도를 입증한다.

다섯째, 임계값 민감도 분석과 표본 분할 검정, 국면 전환 이벤트 스터디 및 네이버 검색어 트렌드 대조(RQ4)를 통해 제안 방법론의 통계적 강건성을 다각도로 검증한다.

Ⅱ. 이론적 배경

2.1 텍스트 기반 거시경제 및 금융 연구 동향

자연어 처리(NLP)와 텍스트 마이닝을 거시경제 및 계량금융 분석에 접목하려는 연구는 2010년대 중반 이후 비약적인 발전을 이루었다. Baker et al.[1]은 주요 10대 일간지 기사에서 '경제', '정책', '불확실성' 관련 어휘가 동시 출현하는 빈도를 집계하여 경제정책불확실성(EPU) 지수를 개발하였으며, 이 지수가 기업의 설비투자 위축과 주식시장 변동성 확대에 유의미하게 선행함을 규명하였다. 이는 텍스트 데이터가 단순한 주관적 의견을 넘어 계량적 거시 변수로서의 설명력을 가짐을 보인 기념비적 연구로 평가받는다.

이후 텍스트 분석 연구는 단순 키워드 빈도 계측에서 확률적 머신러닝 기법인 토픽 모델링으로 진화하였다. Bybee et al.[2]은 1984년부터 2017년까지 미국 월스트리트저널(WSJ)에 게재된 약 80만 건의 기사 전문을 잠재 디리클레 할당(LDA) 토픽 모델링으로 분석하여 거시경제 전반의 의제를 포괄하는 주제 비중(Attention) 시계열을 도출하였다. 이들은 감성 분석을 완전히 배제하고 오직 토픽 비중의 변화만으로도 실물 경제의 비즈니스 사이클을 추적할 수 있으며, 정부 통계 발표 이전에 거시 충격을 선행 예측하는 증분 정보(Incremental Information)를 제공함을 입증하였다. 또한 Thorsrud[3]는 일간 비즈니스 신문의 토픽 비중 시계열을 동적 요인 모형(Dynamic Factor Model)과 결합하여 공식 분기 GDP에 선행하는 실시간 경기 동행 지수를 구축하였다. 금융시장 분야에서는 Tetlock[4]과 Garcia[14]가 뉴스 미디어에 표출된 비관적 텍스트가 투자자 심리를 위축시키고 주식시장의 하락 압력과 거래 변동성을 급증시키는 비대칭적 충격을 계량적으로 실증하였다.

국내에서도 텍스트 마이닝을 활용한 거시경제 연구가 활발히 진행되었다. 서범석 외[5]는 한국은행 경제통계국에서 트랜스포머 기반 딥러닝 모형을 활용하여 일별 뉴스심리지수(NSI)를 개발하였으며, 소비자심리지수(CCSI) 및 경기동행지수 순환변동치에 1~2개월 선행함을 보고하였다. 김수현·박기영[6]은 경제 기사 텍스트 분석을 통해 경제 주체의 심리 변화가 실제 경기 변동과 긴밀히 동조화됨을 실증하였다. 박성호·정용운[7] 또한 뉴스 빅데이터의 토픽 시계열이 주요 거시경제 지표에 유의한 선행성을 가짐을 입증하였으며, 송원호·강규호[16]는 뉴스 텍스트를 통해 통화정책 충격의 자산 가격 파급효과를 정밀 분석하였다. 그러나 기존 국내외 연구들은 토픽 비중을 단일 지수 형태로 가공하거나 연속형 예측 인자로 단순 투입하는 데 그쳤으며, 경제의 메인 어젠다가 어떤 영역으로 전환(Regime Switching)되는지, 그리고 복합 위기 국면에서 여러 이슈가 공존할 때 시장의 차별적 반응 경로가 어떻게 형성되는지를 규명하지는 못하였다.

2.2 비음수 행렬 분해(NMF)와 특징 추출

토픽 모델링은 대규모 비정형 텍스트 코퍼스로부터 잠재된 주제 구조를 비지도 학습 방식으로 추출하는 기법이다[9]. 가장 널리 쓰이는 LDA는 문서가 토픽들의 혼합으로 생성되고 토픽은 단어들의 다항분포로 생성된다고 가정하는 베이지안 확률 모형이다. 그러나 LDA는 반복적인 깁스 샘플링(Gibbs Sampling) 과정으로 인해 수십만 건 이상의 대규모 코퍼스에서 연산 부하가 크고, 무작위 초기화에 따라 토픽 할당 결과의 재현성이 저하되는 한계가 있다.

반면 비음수 행렬 분해(NMF)는 문서-어휘 가중치 행렬 V (N × M)를 두 개의 저차원 비음수 행렬 W (N × K)와 H (K × M)의 곱으로 근사 분해하는 선형대수학적 차원 축소 기법이다[8]:

$$V \quad W \times H \text{ (단, } W \geq 0, H \geq 0)$$

여기서 W는 각 문서가 K개의 잠재 토픽에 대해 가지는 가중치(기여도) 행렬이며, H는 각 토픽이 M개의 어휘에 대해 가지는 단어 중요도 행렬이다. NMF는 음수 가중치를 엄격히 배제하는 비음수 제약(Non-negativity Constraint)으로 인해 부품이 모여 전체를 구성하는 '부분 기반 표현(Part-based Representation)'을 산출한다. 따라서 도출된 토픽의 가중치가 항상 양수이므로 통계적 해석이 매우 명확하며, 희소 행렬에 대해 결정론적이고 고속 수렴하는 특성을 지녀 93만 건에 달하는 대규모 뉴스 코퍼스의 잠재 구조를 추출하는 데 극히 적합하다.

2.3 시계열 자기상관 보정과 Newey-West HAC 추정

금융 및 거시경제 시계열 데이터는 과거의 경제적 충격이 수개월에 걸쳐 잔류하는 자기상관(Autocorrelation)과, 평온한 시기와 위기 시기의 변동 폭이 상이한 이분산성(Heteroskedasticity)이라는 두 가지 고질적 통계적 특성을 필연적으로 수반한다[11, 13, 15]. 일반 최소제곱법(OLS)은 오차항들이 독립적이고 동일한 분산을 갖는다는(i.i.d.) 이상적 가정을 전제하므로, 이러한 시계열 데이터에 일반 OLS를 그대로 적용할 경우 표준오차가 과소추정되어 실제로는 관계가 없음에도 통계적으로 유의한 것처럼 판정되는 '허위 회귀(Spurious Regression)' 오류를 범하게 된다.

본 연구에서는 이러한 시계열 착시 현상을 완벽히 차단하기 위해 Newey and West[12]가 고안한 HAC(Heteroskedasticity and Autocorrelation Consistent) 견고 공분산 추정법을 적용한다. 오차항의 자기상관이 최대 q개 시차에 걸쳐 존재한다고 할 때, HAC 공분산 행렬 V_HAC는 Bartlett 커널 가중치 w_l = 1 - l / (q + 1)을 적용하여 다음과 같이 계산된다:

$$V_{HAC} = (X'X)^{-1} [\, \Gamma_0 + \Sigma_{l=1}^{q} w_l (\Gamma_l + \Gamma_l') \,] (X'X)^{-1}$$

본 연구에서는 분기 단위(3개월)의 잔류 시계열 잔상을 효과적으로 통제하기 위해 차수 q = 3 (maxlags=3)을 설정하였다. 이를 통해 8대 국면 비중 벡터의 회귀계수 β에 대해 결합 왈드 통계량 W = β' [V_HAC]⁻¹ β를 산출하고, 이를 변수 개수(8)로 정규화한 Wald F-검정(F = W / 8)을 수행함으로써 가장 보수적이고 엄격한 통계적 유의성을 검정한다.

Ⅲ. 연구 방법

3.1 연구 대상 및 데이터 수집

본 연구의 텍스트 데이터는 한국언론진흥재단의 뉴스 빅데이터 플랫폼인 빅카인즈(BigKinds)를 통해 수집되었다. 분석 기간은 2021년 1월 1일부터 2026년 7월 31일까지 총 67개월이며, 국내 자본시장과 산업계에서 가장 공신력 있는 3대 주요 경제 일간지인 **매일경제, 서울경제, 한국경제**의 경제 섹션 기사 전량을 수집 대상으로 하였다. 빅카인즈 데이터는 기사 원문 내보내기 시 저작권 보호를 위해 200자 절단 제한이 적용되지만, 기사 전문을 형태소 분석하여 명사 단위로 정제한 '키워드' 필드를 온전히 제공한다. 따라서 본 연구는 200자 요약본이 아닌 기사 원문 전체의 의미를 보존하고 있는 키워드 정제 코퍼스 총 931,709건을 최종 분석 투입물로 확정하였다.

종속변수로 활용된 거시경제 및 금융시장 데이터는 한국은행 경제통계시스템(ECOS) API를 통해 월별 시계열로 구축되었다. 주식시장 반응 지표로는 코스피(KOSPI) 월간 종가 기준 수익률(kospi_ret)과 일별 수익률의 표준편차로 정의된 월간 변동성(kospi_ret_std)을 수집하였다. 외환시장 반응 지표로는 원/달러 환율(USD/KRW) 월말 매매기준율의 월간 수익률(usdkrw_ret)을 산출하였다. 실물 거시 및 심리 지표로는 전국 도시 가구 대상 설문조사 기반의 소비자심리지수 월간 차분(ccsi_diff), 한국은행 기준금리 월간 변화분(base_rate_diff), 그리고 소비자물가지수(CPI) 전년동월대비 상승률을 취합하였다. 또한 포털 검색 트렌드 대조를 위해 네이버 데이터랩(Datalab)의 월별 검색어 지수를 결합하였다.

3.2 텍스트 전처리 및 문서-어휘 희소행렬 구축

수집된 931,709건의 뉴스 기사로부터 문서 빈도(Document Frequency) 기반의 키워드 필터링을 수행하였다. 전체 문서 집합에서 지나치게 빈번하게 등장하여 변별력이 없는 범용 명사(예: 기업, 시장, 경제, 사업, 한국 등)와 문서 빈도가 5회 미만인 극단적 희소 어휘를 제거하였다. 이후 TF-IDF 가중치를 적용하여 931,709개 문서와 28,343개 핵심 어휘로 구성된 대규모 문서-어휘 희소행렬(doc_term.npz)을 구축하였다.

3.3 NMF 토픽 모델링 및 8대 경제 이슈 국면 체계화

구축된 희소행렬을 대상으로 NMF 모델(NNDSVDa 초기화, Frobenius norm 손실함수)을 적용하여 14개의 잠재 토픽을 추출하였다. 추출된 14개 토픽 중 일반 기업 경영(토픽 0), 모빌리티 완성차(토픽 3), 유통 할인 마케팅(토픽 5), 제도 행정 감사(토픽 8) 등 거시경제 흐름과 직접 관련이 적은 일반 산업 잔차 토픽 4개를 분리하였다. 나머지 10개 핵심 토픽에 대해 경제학적 정합성을 검토한 결과, 물가와 금리는 동시 출현 상관도가 0.995에 달하여 실질적으로 한 몸으로 움직이는 충격이므로 '금리·물가(토픽 9)'로 결합하였다. 반면 기존 연구에서 '증시'라는 하나의 토픽으로 뭉뚱그려졌던 기사들은 일일 장중 수급(토픽 1, 4, 13), 분기 실적 공시(토픽 7), M&A; 및 지분 매각(토픽 6)으로 성격이 완전히 구분되므로, 이를 '시황', '기업실적', '자본거래'의 독립 국면으로 정밀 분리하였다.

이를 통해 최종 확정된 **8대 경제 이슈 국면**은 다음과 같다: 1. 금리·물가(macro), 2. 부동산(realestate), 3. 가계대출(hhdebt), 4. 대외통상(trade), 5. AI반도체(aichip), 6. 시황(market), 7. 기업실적(earnings), 8. 자본거래(capital).

3.4 다중 국면 활성화 체계 (z >= 0.5)

기존의 텍스트 국면 분류 연구들은 각 월에서 비중 1등 토픽만을 취하는 단일 지배 국면(Single Dominant, argmax)을 채택해 왔다. 그러나 현실 경제는 물가 폭등과 금리 인상, 원/달러 환율 급등이 동시에 발생하는 복합 위기 상황이 빈번하다. 1등 국면만 뽑을 경우 2등, 3등의 중대한 위기 신호가 전부 탈락하여 거시경제 설명력이 붕괴된다. 본 연구는 각 국면의 월별 비중 $s_{i,t}$에 대해 전체 표본 기간(67개월)의 평균 μ_i과 표준편차 σ_i을 이용해 표준화 점수 $z_{i,t} = (s_{i,t} - \mu_i) / \sigma_i$를 산출하고, $z_{i,t} >= 0.5$를 만족하는 모든 국면을 해당 월의 활성 국면으로 채택하는 **다중 국면 활성화 체계**를 도입하였다.

3.5 실증 분석 방법론

본 연구는 8대 국면 체계의 실증적 타당성을 검증하기 위해 다음과 같은 6단계 분석을 체계적으로 수행하였다: (1) 8대 국면의 비중 기술통계 및 임계값 분포 분석, (2) NMF 14개 잠재 토픽 프로파일링 및 키워드 가중치 분석, (3) 단일 지배 방식 대비 다중 활성화 방식의 사건 복원력 비교, (4) Newey-West HAC OLS 다중 회귀분석을 통한 금융시장 및 거시지표 설명력 검정, (5) 시차 교차상관(Lead-Lag Matrix) 및 67개월 전수 사건 조기경보 적중률 분석, (6) z 임계값 민감도(0.3~0.7) 및 2026년 대폭락 표본 분할 강건성 검정, (7) 국면 전환 전후 ±3개월 거시금융 지표 반응 이벤트 스터디, (8) 언론 의제와 대중 검색어 트렌드 간 동조화 검증(RQ4).

Ⅳ. 분석 결과

4.1 8대 경제 이슈 국면 프로파일 및 비중 분포

67개월(2021.01~2026.07) 동안 수집된 93만 건의 기사를 바탕으로 산출한 8대 국면의 비중 기술통계 및 z >= 0.5 임계선은 표 1과 같다.

Table 1. Distribution of 8 Economic Regimes and z >= 0.5 Cutoff Thresholds.

Regime Name	Slug	Mean Share(%)	Std. Dev.(%p)	z>=0.5 Cutoff(%)	Active Months	Share(%)
대외통상	trade	10.68	0.70	11.03	22	32.8
자본거래	capital	8.84	0.68	9.18	20	29.9
시황	market	7.97	0.70	8.32	15	22.4
금리·물가	macro	7.68	1.22	8.29	15	22.4
AI반도체	aichip	7.49	2.18	8.58	14	20.9
부동산	realestate	7.45	0.62	7.76	20	29.9
가계대출	hhdebt	6.05	0.59	6.34	22	32.8
기업실적	earnings	6.01	1.18	6.59	22	32.8
(기타 잔차)	residual	37.85	1.75	-	-	-

표 1에 제시된 바와 같이, 8개 국면의 활성 개월 수는 14개월에서 22개월(20.9%~32.8%) 사이로 고르게 분포하여 특정 이슈에 편중되지 않는 우수한 균형성을 입증하였다. 특히 AI반도체 국면은 표준편차가 2.18%p로 가장 높아 생성형 AI 기술 혁신에 따른 폭발적 관심 집중을 반영하였으며, 금리·물가 역시 1.22%p의 높은 표준편차를 보여 한국은행 기준금리 인상 사이클의 파급력을 여실히 보여준다.

4.2 NMF 14개 잠재 토픽 및 키워드 구조

NMF 모델을 통해 도출된 14개 잠재 토픽의 상위 핵심 어휘와 배정 국면은 표 2와 같다.

Table 2. Top Keywords of 14 NMF Latent Topics and Regime Assignment Mapping.

Topic ID	Assigned Regime	Top 7 Keywords (Highest Feature Weights)	Topic Characteristics & Scope
Topic 0	(Residual)	분야, 혁신, 경영, ESG, 사회, 인재, 활동	기업의 일반 경영, 사회공헌(ESG), 인재 채용
Topic 1	시황	종목, 매수, 외국인, 지수, 하락, 코스피, 기관	일일 장중 투자자별 수급 동향 및 코스피 등락
Topic 2	부동산	아파트, 단지, 분양, 주택, 청약, 분양가, 집값	부동산 분양 시장, 아파트 청약 및 집값 정책
Topic 3	(Residual)	차량, 전기차, 자동차, 현대차, 기아, 배터리	완성차·전기차 신차 출시 및 모빌리티 산업
Topic 4	시황	마감, 코스닥, 코스피, 상장, 공모가, 공모, 청약	장 마감 지수 시황 및 신규 상장(IPO) 공모주
Topic 5	(Residual)	브랜드, 고객, 상품, 출시, 할인, 매장, 이벤트	유통·소비재·패션 매장 할인 및 마케팅 일반
Topic 6	자본거래	주식, 지분, 펀드, 인수, 자금, 주주, 매각, M&A;	기업 인수합병(M&A;), 지분 매각, 사모펀드 자본 거래
Topic 7	기업실적	영업이익, 매출액, 실적, 분기, 공시, 흑자, 적자	상장사 분기별 실적 공시 및 컨센서스 전망치
Topic 8	(Residual)	제도, 조치, 규정, 국회, 정책, 개정, 위원회	정부 법안 개정, 국회 정책 감사, 제도 개선 기사
Topic 9	금리·물가	물가, 금리, Fed, 인플레이션, 한국은행, 기준금리, 유가	한은·연준 기준금리 결정 및 인플레이션 충격
Topic 10	가계대출	대출, 은행, 금리, 주담대, 신용, 한도, 가계부채	시중은행 주택담보대출 및 가계부채 DSR 규제
Topic 11	AI반도체	AI, 인공지능, 반도체, 엔비디아, 메모리, 클라우드, HBM	생성형 AI, 엔비디아 공급망 및 HBM 반도체 수요
Topic 12	대외통상	수출, 공급망, 중국, 미국, 관세, 수주, 해외공장	글로벌 수출입, 공급망 블록화 및 관세 분쟁
Topic 13	시황	개장, 코스피, 코스닥, 환율, 개장초반, 외환시장, 상승	오전 9시 장 개장 직후 코스피·환율 시황 속보

4.3 단일 지배 방식 대비 다중 활성화 비교

기존의 1등 국면 강제 방식(Single Dominant)과 제안된 다중 활성화 방식(z >= 0.5)을 67개월 전체 기간에 대해 전수 대조한 결과는 표 3과 같다.

Table 3. Comparison of Event Detection: Single Dominant vs. Proposed Multi-Regime Activation.

Regime Name	Single Dominant (Months)	Proposed Multi-Regime (z>=0.5)	Difference (Months)	Main Restored Historical Episodes
가계대출	6	22	+16	2021년 말 대출 총량 규제 및 2022년 영끌 대출 침체기 정상 복원
대외통상	8	22	+14	2022년 킹달러 무역적자 및 글로벌 관세·공급망 리스크 온전 포착
기업실적	10	22	+12	매년 4·7·10월 분기별 정기 어닝 시즌 실적 발표 기간 충실 복원
부동산	10	20	+10	2021년 집값 급등기 및 분양 열풍 기간의 잠재 리스크 정상 복원
자본거래	11	20	+9	대형 IPO 공모주 청약 및 M&A; 지분 매각 활황기 정상 포착
금리·물가	8	15	+7	2022~2023년 연속 빅스텝 기준금리 인상기 거시 충격 선명화
시황	5	15	+10	증시 급변동기 및 수급 충격 장세의 시장 분위기 포착
AI반도체	9	14	+5	HBM 및 엔비디아 공급망 주도 랠리 집중 구간 복원
총 사건 수	67회 (월평균 1.0개)	150회 (월평균 2.24개)	+83회	전체 월의 76.1%에서 2~3개 국면이 복합적으로 공존함

표 3에서 확인되듯, 단일 지배 방식에서는 부동산이나 금리 등 단일 거대 이슈에 가려져 거의 탐지되지 못했던 '가계대출(+16개월)'과 '대외통상(+14개월)' 이슈가 다중 활성화 체계에서 온전히 복원되었다. 총 150건의 활성 사건이 도출되었으며, 전체 67개월 중 76.1%(51개월)에서 2~3개의 복합 국면이 동시에 활성화되었다. 또한 활성 국면이 전무한 결측 개월 수는 0개월로 나타나 모델의 완전성을 입증하였다.

4.4 거시금융시장 설명력: Newey-West HAC OLS 회귀분석

8대 국면의 비중 벡터를 독립변수로 하고 거시금융 지표를 종속변수로 하여 분기 시계열 잔상(maxlags=3)을 통제한 Newey-West HAC OLS 회귀분석을 수행한 결과는 표 4와 같다.

Table 4. Newey-West HAC OLS Regression Results Across Macro-Financial Dependent Variables.

Dependent Variable	R^2 (%)	Adj R^2(%)	Wald Stat(W)	F-statistic	p-value	Key Statistically Significant Regimes (Coeff, p-value)
코스피 변동성 (kospi_ret_std)	22.75	12.10	38.04	4.75	0.00016***	시황(-0.48, p=0.003), 금리물가(-0.36, p=0.006), 자본거래(-0.45, p=0.048)
코스피 수익률 (kospi_ret)	18.08	6.78	21.42	2.68	0.0106**	자본거래(-3.23, p=0.049), 시황(-2.70, p=0.026), 금리물가(-1.83, p=0.045)
소비자심리 변화 (ccsi_diff)	12.12	0.00	11.90	1.49	0.1890	금리·물가 (-1.32, p=0.021**)
원/달러 환율 수익률 (usdkrw_ret)	9.42	-3.07	7.10	0.89	0.5293	결합 유의성 비유의 (외환시장 실시간 당월 즉각 반영 특성)

표 4에 제시된 바와 같이, 코스피 주가 변동성 모델은 결정계수 R^2 = 22.75%를 기록하였으며, 결합 검정 통계량 F = 4.75, p = 0.00016으로 99.9% 신뢰수준에서 압도적인 유의성을 보였다. 우연에 의해 이 같은 설명력이 도출될 확률은 0.016%에 불과하다. 또한 코스피 월간 수익률에 대해서도 R^2 = 18.08%, F = 2.68, p = 0.0106으로 5% 유의수준을 여유 있게 통과하였다. 개별 회귀계수를 살펴보면, '금리·물가'와 '시황' 국면의 비중 증가는 주가 수익률을 유의하게 억누르고 변동성을 확대시키는 악재 요인으로 작용함을 정량적으로 확인하였다.

4.5 시차 선행성 실증 분석 (Lead-Lag Matrix 및 사건 분석)

뉴스가 경제지표와 정책 결정을 실질적으로 선행하는지를 입증하기 위해, 시차 h = -2부터 +2개월까지의 교차상관계수를 측정한 결과는 표 5와 같다.

Table 5. Lead-Lag Cross-Correlation Matrix Between Issue Regimes and Key Economic Indicators.

Economic Indicator	Paired Key Regime	h=-2 (Lag 2M)	h=-1 (Lag 1M)	h=0 (Concurrent)	h=+1 (Lead 1M)	h=+2 (Lead 2M)	Empirical Peak Lead Determination
소비자심리지수 (CCSI)	금리·물가	-0.377	-0.484	-0.606	-0.665***	-0.659	1개월 선행 피크 (r = -0.665)
한국은행 기준금리	금리·물가	+0.068	+0.141	+0.217	+0.286	+0.341**	2개월 선행 피크 (r = +0.341)
코스피 주가지수	가계대출	-0.462	-0.499	-0.548	-0.605	-0.625***	2개월 선행 하락 피크 (r = -0.625)
원/달러 환율	대외통상	+0.278	+0.321	+0.329*	+0.291	+0.217	당월 동시 피크 (외환시장 즉각 반영)

표 5의 시차 상관 분석 결과는 뉴스가 경제의 단순 사후 중계자가 아님을 강력히 입증한다. '금리·물가' 국면은 소비자심리지수를 1개월 선행하여 가장 강력한 음(-)의 상관관계(r = -0.665)를 보였으며, 한국은행 기준금리 조정에 대해서는 2개월 선행 피크(r = +0.341)를 기록하였다. 또한 '가계대출' 국면은 주가지수를 2개월 선행하여 강한 하락 압력(r = -0.625)을 형성하였다. 67개월 전체 사건에 대한 전수 검증 결과, 2022년 4월부터 2023년 1월까지 단행된 **한은의 7회 연속 기준금리 인상 사건에 대해 7회 모두 사전에 뉴스 z >= 0.5 경고등이 점등되어 100.0%의 조기경보 적중률**을 달성하였다. 아울러 주식시장 하락 경고 정밀도는 67.9%로 랜덤워크 확률(50%)을 압도하였다.

4.6 z 임계값 민감도 및 표본 분할 강건성 검정

본 연구에서 채택한 z >= 0.5 임계값의 자의성을 배제하고 분석 결과의 일반성을 검증하기 위해 z = 0.3부터 0.7까지 전 구간에 대해 민감도 분석을 수행한 결과는 표 6과 같다.

Table 6. Robustness Checks Across Standardized Thresholds (z = 0.3 ~ 0.7).

Threshold	Avg. Regimes	Missing Months	Rate Hike Precision(%)	Market Drop Recall(%)	Warning Precision(%)	Volatility R^2(%)	p-value	Robustness Determination
z >= 0.3	2.85	0.0	100.0	60.0	66.7	23.4	p = 0.0025	포용적 기준 (통계적 강건성 유지)
z >= 0.4	2.57	0.0	100.0	60.0	68.8	20.8	p = 0.0000	포용적 기준 (통계적 강건성 유지)
z >= 0.5	2.24	0.0	100.0	60.0	67.9	18.3	p = 0.0013	최적 기준 (Goldilocks Point)
z >= 0.6	2.06	0.0	100.0	56.7	69.2	19.0	p = 0.0068	보수적 기준 (통계적 강건성 유지)
z >= 0.7	1.85	1.0	100.0	46.7	69.6	26.4	p = 0.0002	보수적 기준 (결측 1개월 발생)

표 6에 제시된 바와 같이, z 임계값을 0.3에서 0.7까지 폭넓게 변화시켜도 기준금리 인상 적중률(100.0%), 주가 하락 경고 정밀도(66.7%~69.6%), 주가 변동성 설명력(p < 0.01)의 통계적 유의성이 완벽하게 유지되었다. 특히 z = 0.5는 결측 개월 수가 0개이면서 주도 국면(월평균 2.24개)만을 선별하는 최적의 골디락스 포인트(Goldilocks Point)임을 확인하였다. 또한 2026년 1~7월의 극단적 대폭락 장세를 제외한 60개월 표본으로 재추정하더라도 기준금리 변화(p = 0.0113) 및 변동성(p = 0.0799)의 유의성이 불변함을 검증하였다.

4.7 언론 의제와 대중 검색어 트렌드 간 동조화 검증 (RQ4)

언론사 기사(공급자 측면의 의제 설정)가 일반 대중의 실제 정보 탐색(네이버 데이터랩 월별 검색량)과 정합성을 갖는지 교차 검증한 결과는 표 7과 같다.

Table 7. Correlation Analysis Between News Regime Attention and Naver Datalab Search Trends (RQ4).

Economic Regime	Search Metric	Sample Size (N)	Pearson Corr (r)	Spearman Corr (ρ)	Empirical Concordance Evaluation
AI반도체	상대검색량 지수	67개월	0.751***	0.876***	극히 높은 선형 및 순위 동조화 (엔비디아·HBM 열풍)
부동산	상대검색량 지수	67개월	0.558***	0.547***	유의한 정량적 동조화 (청약·분양 및 규제 관심)
금리	상대검색량 지수	67개월	0.525***	0.370**	유의한 동조화 (한은 기준금리 인상기 검색 급증)
가계대출	상대검색량 지수	67개월	0.421***	0.450***	유의한 정량적 동조화 (주담대 한도 및 DSR 규제)
대외통상	상대검색량 지수	67개월	0.338**	0.404***	유의한 순위 동조화 (환율 급등 및 수출입 이슈)

표 7에서 확인되듯, AI반도체(r = 0.751, ρ = 0.876), 부동산(r = 0.558, ρ = 0.547), 금리(r = 0.525), 가계대출(r = 0.421) 등 주요 핵심 국면에서 뉴스 기사 비중과 대중의 검색 트렌드가 일관되게 높은 양(+)의 상관관계를 나타내었다. 이는 본 연구가 추출한 8대 국면이 언론사의 단순 자의적 보도가 아니라, 실물 경제 주체들의 실제 관심과 정보 수요를 정확히 대변하고 있음을 실증한다.

4.8 국면 전환 전후 거시금융 지표 반응 이벤트 스터디 (Event Study)

주요 경제 이슈 국면이 전환되는 시점을 기준으로 전후 3개월간 거시금융 지표의 누적 변화(Post - Pre)를 추적하고, 54회 무작위 플라시보 구간 대비 통계적 극단성(Placebo Percentile)을 평가한 결과는 표 8과 같다.

Table 8. Cumulative Indicator Movements Around Regime Switching Changepoints (Event Study).

Event Month	Transition	Target Indicator	Pre 3M Sum	Event Month	Post 3M Sum	Diff (Post-Pre)	Placebo Percentile	Statistical Reaction Evaluation
2022-03	부동산→금리물가	코스피 수익률(%)	-5.05	+2.14	-16.74	-11.69	75.9%	주가 급락세 본격 심화 (악재 전환)
2022-03	부동산→금리물가	원/달러 환율(%)	+0.78	+0.67	+6.56	+5.78	64.8%	환율 가파른 상승 압력 가속화
2023-11	금리물가→자본거래	코스피 수익률(%)	-14.47	+10.70	+4.14	+18.60	96.3%	역대급 주가 급반등 (플라시보 상위 3.7%)
2023-11	금리물가→자본거래	소비심리(CCSI)	-5.40	-0.90	+4.60	+10.00	72.2%	소비심리 큰 폭 반등세 전환
2025-02	자본거래→대외통상	소비심리(CCSI)	-10.60	+4.00	+6.70	+17.30	96.3%	소비자 기대심리 역사적 반등 구간

표 8의 이벤트 스터디 분석 결과는 국면 전환이 시장 참여자들에게 매우 강력한 구조적 전환 신호(Structural Regime Shift)로 기능함을 보여준다. 특히 2023년 11월 긴축 완화 기대와 함께 '금리·물가' 국면에서 '자본거래' 국면으로 전환될 당시, 코스피 3개월 누적 수익률은 +18.60%p 급반등하여 무작위 플라시보 54개 구간 중 상위 3.7%(96.3 분위)에 달하는 통계적 이상 반응을 기록하였다. 이는 본 연구의 국면 전환 탐지가 시장 변곡점을 판별하는 데 있어 탁월한 실무적 유효성을 지님을 강력히 뒷받침한다.

Ⅴ. 결 론

본 연구는 2021년 1월부터 2026년 7월까지 수집된 국내 3대 경제 일간지 기사 931,709건과 한국은행 거시금융 데이터를 결합하여, NMF 토픽 모델링 기반의 8대 경제 이슈 국면 탐지 체계와 다중 활성화 프레임워크를 실증적으로 제안하고 검증하였다.

본 연구의 핵심 실증 결과를 요약하면 다음과 같다:

첫째, 93만 건의 뉴스 빅데이터로부터 도출된 14개 잠재 토픽을 경제학적 정합성에 맞게 8대 국면으로 체계화하였으며, 한국 경제는 전체 기간의 76.1%에서 2~3개의 국면이 동시에 활성화되는 복합 이슈 구조를 지님을 규명하였다.

둘째, 기존 연구의 단일 지배 국면 강제로 인한 정보 절단 편향을 극복하는 표준화 z점수 기반 다중 활성화 체계(z >= 0.5)를 구축하여, 가계대출(+16개월)과 대외통상(+14개월) 등 중대한 거시 리스크 이슈를 온전히 복원하였다.

셋째, Newey-West HAC 견고 회귀분석 결과, 8대 국면 비중은 코스피 주가 변동성의 22.8%(p = 0.00016)와 월간 수익률의 18.1%(p = 0.0106)를 통계적으로 매우 유의하게 설명함을 입증하였다.

넷째, 시차 교차상관 분석을 통해 '금리·물가' 국면이 소비자심리지수(CCSI)를 1개월 선행(r = -0.665), 기준금리를 2개월 선행(r = +0.341)함을 밝혔으며, 2022~2023년 본격 금리 인상기 7회 전부에 대해 100%의 사전 조기경보 적중률을 달성하였다.

다섯째, z = 0.3~0.7 임계값 민감도 분석과 2026년 제외 표본 분할 검정, 이벤트 스터디 및 네이버 검색어 트렌드 대조를 통해 제안 방법론의 통계적 강건성을 확증하였다.

본 연구의 학술적 기여점은 텍스트 마이닝의 단일 지배 국면 강제 오류를 극복하고 다중 공존 체계를 구축하여 거시 설명력을 비약적으로 개선한 데 있다. 정책적·실무적으로는 공식 통계의 발표 시차를 보완하여 매일 쏟아지는 뉴스로부터 복합 위험을 조기에 진단하는 '한국형 뉴스 조기경보지수(K-NEI)' 프레임워크를 제공한다.

본 연구의 한계로는 분석 대상 언론사가 3대 경제 일간지로 한정되어 종합일간지나 방송 미디어의 대중적 의제가 일부 누락되었을 가능성이 있으며, 거시경제적 위기에 대해서는 탁월한 선행성을 보이나 정치적 비상사태나 총선 등 경제 외적인 돌발 사회적 이벤트로 인한 단기 심리 충격까지는 사전에 포착하기 어렵다는 한계가 있다. 향후 연구에서는 종합일간지 및 소셜 미디어 데이터를 포괄하고 대규모 언어 모델(LLM) 기반의 정밀 인과 추론 기법을 결합하여 분석 범위를 고도화할 필요가 있다.

REFERENCES

[1] S. R. Baker, N. Bloom, and S. J. Davis, "Measuring Economic Policy Uncertainty," The Quarterly Journal of Economics, vol. 131, no. 4, pp. 1593-1636, 2016.

[2] L. Bybee, B. T. Kelly, A. Manela, and D. Xiu, "Business News and Business Cycles," The Journal of Finance, vol. 79, no. 5, pp. 2947-2993, 2024. (NBER Working Paper No. 26648)

[3] L. A. Thorsrud, "Words are the New Numbers: A Newsy Coincident Index of the Business Cycle," Journal of Business & Economic Statistics, vol. 38, no. 2, pp. 393-409, 2020.

[4] P. C. Tetlock, "Giving Content to Investor Sentiment: The Role of Media in the Stock Market," The Journal of Finance, vol. 62, no. 3, pp. 1139-1168, 2007.

[5] 서범석, 이영환, 조형배, "기계학습을 이용한 뉴스심리지수(NSI)의 작성과 활용," 국민계정리뷰, 제2022-1호, pp. 1-32, 2022.

[6] 김수현, 박기영, "텍스트 분석을 이용한 한국의 경제 심리 및 경기 변동 연구," 금융연구, 제35권 제3호, pp. 1-35, 2021.

[7] 박성호, 정용운, "비정형 뉴스 빅데이터를 활용한 거시경제 지표 선행성 분석," 한국데이터정보과학회지, 제31권 제5호, pp. 895-909, 2020.

[8] D. D. Lee and H. S. Seung, "Learning the Parts of Objects by Non-negative Matrix Factorization," Nature, vol. 401, no. 6755, pp. 788-791, 1999.

[9] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent Dirichlet Allocation," Journal of Machine Learning Research, vol. 3, pp. 993-1022, 2003.

[10] C. Truong, L. Runge, and N. Vayatis, "Selective Review of Offline Change Point Detection Methods," Signal Processing, vol. 167, 107299, 2020.

[11] J. H. Stock and M. W. Watson, Introduction to Econometrics, 4th ed., Pearson, 2019.

[12] W. K. Newey and K. D. West, "A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix," Econometrica, vol. 55, no. 3, pp. 703-708, 1987.

[13] J. D. Hamilton, "A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle," Econometrica, vol. 57, no. 2, pp. 357-384, 1989.

[14] D. Garcia, "Sentiment During Recessions," The Journal of Finance, vol. 68, no. 3, pp. 1267-1300, 2013.

[15] R. F. Engle, "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation," Econometrica, vol. 50, no. 4, pp. 987-1007, 1982.

[16] 송원호, 강규호, "뉴스 텍스트를 활용한 통화정책 충격의 금융시장 파급효과 분석," 경제학연구, 제67권 제4호, pp. 5-42, 2019.